



CARRERA DE ESPECIALIZACIÓN EN INTELIGENCIA ARTIFICIAL

MEMORIA DEL TRABAJO FINAL

Modelo de inteligencia artificial para la regulación de temperatura en equipos de inducción de hipotermia

Autor:

Ing. Ezequiel Fernández

Director:

Dr. Lic. Tobías Canavesi (FIUBA)

Jurados:

Nombre del jurado 1 (pertenencia)

Nombre del jurado 2 (pertenencia)

Nombre del jurado 3 (pertenencia)

*Este trabajo fue realizado en la Ciudad Autónoma de Buenos Aires,
entre octubre de 2024 y abril de 2025.*

Resumen

En la presente memoria se describe el diseño e implementación de un modelo de inteligencia artificial para la empresa Amrra Electromedicina, en el marco del programa de vinculación. El objetivo del trabajo fue construir un modelo para regular la temperatura en un sistema de inducción de hipotermia y compararlo con el algoritmo que funciona actualmente en los equipos. Para el desarrollo fue fundamental la incorporación de los conocimientos adquiridos en la carrera tales como análisis y preprocesamiento de datos, algoritmos de inteligencia artificial, arquitecturas de aprendizaje profundo y programación en Python.

Agradecimientos

Esta sección es para agradecimientos personales y es totalmente **OPCIONAL**.

Índice general

Resumen	I
1. Introducción general	1
1.1. Introducción	1
1.2. Motivación	3
1.3. Conceptos generales	3
1.4. Objetivos y alcance	4
1.5. Estado del arte	5
2. Introducción específica	7
2.1. Protocolo	7
2.2. Contextos de uso del equipo	8
2.3. Redes neuronales informadas por física	9
2.3.1. Redes neuronales	9
2.3.2. Consideraciones físicas	10
2.4. Herramientas de software	12
3. Diseño e implementación	15
3.1. Arquitectura general del sistema	15
3.2. Análisis de los datos	16
3.3. Preprocesamiento de datos	19
4. Ensayos y resultados	21
4.1. Pruebas funcionales del hardware	21
5. Conclusiones	23
5.1. Conclusiones generales	23
5.2. Próximos pasos	23
Bibliografía	25

Índice de figuras

1.1. Diagrama de funcionamiento del equipo.	2
1.2. Diagrama del equipo con el nuevo modelo.	3
2.1. Evolución de la temperatura del paciente.	8
2.2. Ilustración del algoritmo de descenso del gradiente.	10
2.3. Ejemplo de función de costo.	11
2.4. Ejemplo de función de costo.	12
2.5. Diagrama de herramientas de software.	13
3.1. Arquitectura de modelos del trabajo.	16
3.2. Distribución de temperaturas de los pacientes.	17
3.3. Distribución de temperaturas objetivo.	17
3.4. Distribución de pesos de los pacientes.	18
3.5. Correlación entre las variables.	18

Índice de tablas

1.1. Estado del arte	6
2.1. Contextos de uso	8

Dedicado a... [OPCIONAL]

Capítulo 1

Introducción general

En este capítulo se presentan conceptos básicos sobre inducción de hipotermia y los equipos involucrados. También se comenta el contexto y las motivaciones que impulsan la realización de este trabajo. Además se menciona el alcance y los objetivos, y se analiza el estado del arte en el campo de estudio.

1.1. Introducción

El objetivo de este trabajo fue desarrollar un modelo de inteligencia artificial prototipo que estime la temperatura del agua que circula en un equipo utilizado para la inducción de hipotermia a pacientes neonatales. Además el cálculo de la incidencia de los parámetros en el modelo implementado resulta importante para aportar al conocimiento sobre estos tratamientos. Esto puede significar a futuro una mejora en un producto que desarrolla la empresa y brindar a quienes necesiten este tratamiento un desarrollo superador respecto al actual. El trabajo fue desarrollado dentro del marco del programa de vinculación.

La empresa es Amrra [1] y los equipos en cuestión tienen el nombre Amrraterm HTF. Estos sistemas se utilizan con el propósito de inducir una hipotermia controlada en pacientes neonatales. Existen contextos en los que esto proporciona una mejor evolución de los pacientes. El principal caso de uso es el de pacientes que sufren hipoxia al nacer, esto es, falta de oxígeno en el cerebro. En estos casos, a temperatura corporal normal la interacción entre las neuronas es alta y se pueden desarrollar efectos adversos en la capacidad cerebral del paciente. Por esto un tratamiento estándar es el de inducir hipotermia por 72 horas a fin de minimizar los efectos que la hipoxia puede generar a futuro en los pacientes.

Para lograr esto el procedimiento es sedar al paciente y colocarlo dentro de una incubadora, donde es envuelto en las mantas que forman parte del equipo. Por estas mantas circula agua destilada. El equipo recibe como dato de entrada la temperatura objetivo a la cual se quiere llevar al paciente, que suele ser de 33,5 °C, y regula la temperatura del agua en función de la temperatura objetivo y la actual del paciente. Una vez terminado el tratamiento de hipotermia, el equipo funciona en un modo en el que sube paulatinamente la temperatura hasta llegar a un estado normal.

En la actualidad, la temperatura del agua es regulada por un algoritmo de lógica difusa. En un rango de pesos estándar de los pacientes (entre 2,5 kg y 3,5 kg) el algoritmo funciona correctamente, pero es posible que en pesos inferiores o superiores haya comportamientos que este proyecto pueda mejorar. Se desarrolló

este modelo para evaluar si funciona mejor que el algoritmo actual en ese rango, en los valores inferiores o en los superiores de peso.

Se utilizaron diversos datos para construir un modelo acorde al problema como el peso del paciente, la edad, la temperatura objetivo y las variaciones de temperatura del agua y paciente. Además de construir un modelo superador, también se busca detectar la incidencia de ciertos parámetros, como el peso del paciente, que no se utiliza por el algoritmo actual. Para evaluar el comportamiento del modelo se implementa un entorno que permita ingresar datos y visualizar la respuesta del modelo para los datos ingresados.

Los principales componentes del equipo son una interfaz de uso, un sistema de mantas y cañerías, un sistema térmico y un algoritmo de lógica difusa. Mediante la interfaz, el personal de salud indica los datos del tratamiento, como son el peso y la duración. A través del sistema de mantas y cañerías circula agua destilada a una determinada temperatura. El sistema térmico tiene la responsabilidad de administrar la energía para que el agua esté a la temperatura indicada. Por último, el algoritmo es responsable de calcular la temperatura óptima del agua para el tratamiento. Un diagrama de esto se puede apreciar en la figura 1.1.

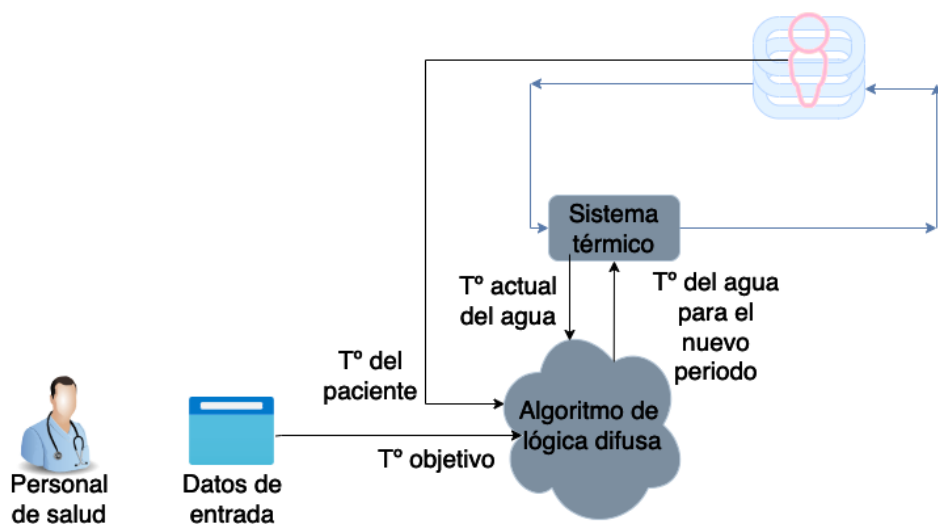


FIGURA 1.1. Diagrama de funcionamiento del equipo.

El modelo implementado cumple el mismo rol que el algoritmo que funciona actualmente, por lo que en el diagrama se lo puede ubicar a la par. Además de la temperatura objetivo, la actual del agua y la actual del paciente, recibe el peso del paciente. Se propone que funcionen un tiempo en paralelo y un elector defina cuál de las temperaturas elegidas aplicar. Esto se describe en la figura 1.2.

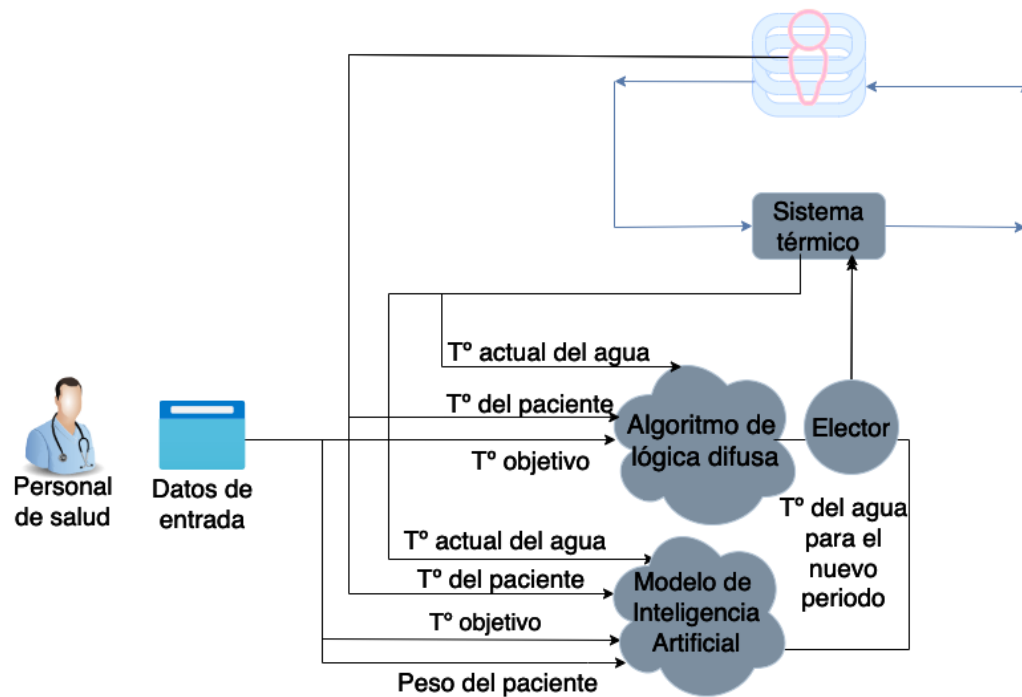


FIGURA 1.2. Diagrama del equipo con el nuevo modelo.

1.2. Motivación

Existen dos motivaciones fundamentales para el desarrollo de este trabajo. En primer lugar está la incorporación de técnicas de inteligencia artificial para el modelado de tratamientos de inducción de hipotermia en los equipos mencionados. Esto supone una actualización al modelado actual mediante la incorporación de nuevas tecnologías y estrategias. Se puede esperar un comportamiento superior del sistema, lo que implicaría una mejor evolución en los pacientes. En segundo lugar está la incorporación del peso como variable para modelar el problema, lo que supone un mejor comportamiento y nuevamente, una mejoría en la evolución de los pacientes. Además, esto permitirá conocer la incidencia de esta variable en el problema, fortaleciendo el conocimiento sobre este tratamiento. Sin embargo, es posible que el modelo resultante no se comporte mejor que el algoritmo actual. Estos equipos están en funcionamiento en una gran cantidad de hospitales en todo el país, y su funcionamiento es aceptado por la comunidad médica. En este caso, igual este trabajo aportará valor a la empresa, ya que brindará información acerca de la incidencia de los parámetros, y esto brindará un crecimiento en el conocimiento que se tiene sobre estos tratamientos.

1.3. Conceptos generales

A continuación se definirán algunos conceptos y valores importantes para la temática. Como se mencionó anteriormente, los equipos en cuestión se denominan Amrraterm HTF. Algunos son propiedad de la empresa y se alquilan en centros

de salud, mientras que otros fueron adquiridos. Están en funcionamiento en hospitales públicos y privados. Su dominio es acotado al tratamiento de regulación de temperatura en pacientes neonatales, esto es, en recién nacidos. El principal caso de uso es el de provocar una hipotermia controlada en pacientes que sufren hipoxia al nacer. Para esto, el profesional establece una temperatura a la que quiere llevar al paciente, denominada objetivo. Los tratamientos suelen durar 72 hs. aproximadamente, y en este tiempo el tratamiento se desarrolla en tres etapas. La primera, llamada rampa hacia abajo, se da en los primeros minutos del tratamiento, periodo en el que se busca llevar la temperatura del paciente hacia la objetivo, producto de la circulación de agua fría por las mantas. En la segunda etapa prima la estabilidad, aquí el objetivo es mantener al paciente en la temperatura objetivo. En la última etapa, denominada rampa hacia arriba, producto de la circulación de agua con mayor temperatura en las mantas del equipo, el paciente recupera su temperatura normal. Al establecer los parámetros del tratamiento, el profesional indica el peso del paciente. Este dato no es tenido en cuenta por el algoritmo actual pero sí se utiliza para el entrenamiento de los modelos de este trabajo. Los pacientes suelen estar en un peso superior a 2,5 kg e inferior a 3,5 kg. En porcentaje, el desvío de este valor no es despreciable.

Se pueden distinguir los siguientes atributos:

- Temperatura objetivo, a la que se quiere llevar al paciente.
- Temperatura del agua que circula por las mantas.
- Temperatura actual del paciente en un instante del tiempo.
- Peso del paciente.

Uno de los criterios de bondad para estos equipos es que, en la etapa estable, la temperatura del paciente diste lo mínimo posible del objetivo. En la práctica se ve que la temperatura oscila sobre el valor esperado, por lo que un modelo será mejor que el actual, en la etapa estable, si la amplitud de la oscilación sobre el objetivo es menor.

1.4. Objetivos y alcance

Para el presente proyecto se plantean objetivos funcionales y conceptuales. Desde el punto de vista funcional se busca el desarrollo de una solución de inteligencia artificial acorde al problema planteado, lo que significa un nuevo enfoque respecto a lo que utilizan actualmente, una actualización y una potencial mejora de su producto. Desde el lado conceptual, se busca entender la incidencia de los parámetros, con mayor énfasis en el peso y en el comportamiento del modelo respecto a pacientes de distinto peso.

Se definieron los siguientes requerimientos:

1. Requerimientos funcionales:

- a) El modelo debe predecir el cambio de temperatura óptimo a aplicar.
- b) La salida del modelo debe ser conceptualmente análoga a la del algoritmo de lógica difusa utilizado actualmente, a fin de poder compararlos.

- c) El modelo debe dar una respuesta en un tiempo promedio menor o igual a 10 veces el tiempo promedio de respuesta del algoritmo actual.
 - d) El sistema debe permitir ingresar datos de forma manual y mostrar el resultado.
 - e) Se debe calcular la incidencia del peso y de los demás atributos en la solución.
2. Requerimientos conceptuales:
- a) Deben utilizarse datos sintéticos en las pruebas.
3. Requerimiento de testing:
- a) Se deben ejecutar pruebas secuenciales con datos reales y mostrar una comparación entre los resultados del modelo a implementar y del algoritmo actual.
 - b) Se deben comparar tiempos entre el modelo propuesto y el algoritmo actual.
 - c) Se debe calcular una métrica a definir para calcular la performance del modelo.
4. Requerimiento de documentación:
- a) Se deben documentar las decisiones tomadas.
 - b) Se deben documentar los resultados de las pruebas y las distintas métricas.
 - c) Se requiere documentar el código y las formas de utilizar al sistema.
5. Requerimiento asociados con regulaciones:
- a) Se requiere que los casos utilizados no expongan datos que infrinjan derechos de privacidad.

El proyecto no incluye:

- La incorporación del modelo a los equipos en funcionamiento.
- El despliegue del modelo en la nube.
- El desarrollo de una interfaz gráfica, una aplicación o una web.

1.5. Estado del arte

En el artículo [2] se habla acerca del tratamiento de inducción de hipotermia. Se mencionan estudios donde se realiza el tratamiento, algunos valores seguros para su desarrollo y se analiza la evolución de los pacientes. Esto puede ser útil para definir rangos de temperaturas adecuadas para el modelado del problema y tener más conocimiento del contexto. Pero no se plantean soluciones de software para llevar a cabo los tratamientos. Por otro lado están los artículos [3], [4], [5] y [6] que analizan el uso de diversos modelos de *machine learning* con el objetivo de predecir potenciales casos de hipotermia. También se analizó el artículo [7] que mediante inteligencia artificial busca predecir el daño causado por la hipotermia. Estos enfoques son interesantes para evaluar los riesgos de someter al paciente

bajo este tratamiento pero no son el objetivo de este trabajo. En este caso el foco estará en un modelo que regule de forma óptima la inducción a hipotermia de un paciente. Por esto, solo el primer artículo puede aportar información relevante al problema. En la tabla 1.1 se muestran las principales características de las lecturas mencionadas.

TABLA 1.1. Comparación de lecturas encontradas.

Artículo	Pacientes	Objetivo
[2]	Pediátricos	Análisis de tratamientos de hipotermia
[3]	General	Predicción
[4]	Pediátricos	Predicción
[5]	General	Predicción
[6]	General	Predicción
[7]	General	Análisis de daño

Capítulo 2

Introducción específica

En este capítulo se describe el contexto y el protocolo bajo los que se espera que el modelo funcione. También se describen los conceptos de inteligencia artificial aplicados y las consideraciones físicas que se tuvieron en cuenta. Además se mencionan las herramientas de software utilizadas.

2.1. Protocolo

Cuando un centro de salud adquiere o alquila un equipo se los capacita para su uso correcto. En la capacitación se menciona un protocolo que es recomendable utilizar para el desarrollo del tratamiento. Esto nace del estudio de los tratamientos en general y de las particularidades del equipo. El sistema permite regular la temperatura de un paciente neonatal a partir de establecer un objetivo. Esto ofrece una gran variedad de campos de uso, pero el principal caso es el de utilizar el equipo para inducir hipotermia. Por esto, se establece el protocolo para este caso como se describe a continuación:

- Se debe colocar al paciente dentro de una incubadora.
- El paciente debe estar sedado.
- La temperatura objetivo debe ser de 33,5 °C.
- No se debe mover al niño.

Bajo estas condiciones el funcionamiento del equipo es muy bueno, el error en las mediciones se reduce y se mantiene al paciente en una temperatura estable. En la imagen 2.1 se puede ver como evoluciona la temperatura del paciente, tomado de la pantalla del equipo.

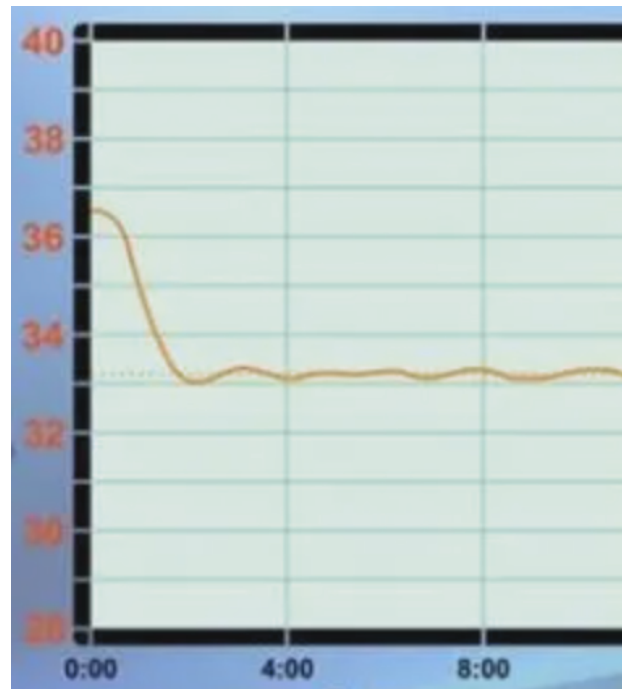


FIGURA 2.1. Evolución de la temperatura del paciente.

2.2. Contextos de uso del equipo

Si bien se detalla el protocolo a seguir, y en muchos casos se tiene en cuenta, existen casos en los que no. En algunos tratamientos la temperatura objetivo es establecida en 32.5 °C, y en otros fue establecida en otros valores, entre los 30 °C y los 35 °C. Además se dan situaciones en las que el paciente no está correctamente sedado en la incubadora. Esto produce que el equipo tarde más de lo usual en llevarlo al objetivo y que la oscilación de la temperatura del paciente sea mayor. También se da que se mueve al niño, y esto produce que en ese momento la temperatura diste del objetivo. Estos contextos se comparan en la tabla 2.1.

TABLA 2.1. Comparación de contextos de uso.

Situación	Consecuencia
Temperatura objetivo distinta	Tratamiento no estándar e impreciso
Paciente que no está sedado	Tratamiento impreciso
Se mueve al paciente	Tratamiento impreciso por un lapso de tiempo

Como se mencionó, estos contextos de uso reducen la eficiencia del funcionamiento del equipo. Esto genera una oportunidad para el nuevo modelo. Se espera que esta nueva herramienta tenga mayor robustez y se comporte mejor ante contextos diversos. Esto puede lograrse a partir de un aprendizaje sólido y de un conjunto de datos amplio. Además diversas estrategias pueden ser aplicadas para maximizar la robustez del modelo. Esto se comentará en el siguiente capítulo.

2.3. Redes neuronales informadas por física

En esta sección se describen conceptos generales de redes neuronales y el enfoque de redes informadas por física, que son los fundamentos el desarrollo de los modelos.

2.3.1. Redes neuronales

Para el desarrollo de este trabajo se utilizaron diversos algoritmos de inteligencia artificial, siendo las redes neuronales las que mejores resultados presentaron. Las redes neuronales artificiales (RNA) son modelos computacionales que se inspiran en el funcionamiento del cerebro humano. La unidad de procesamiento fundamental de las redes neuronales suele ser denominada perceptrón o neurona. Este recibe un vector de señales de entrada $x = (x_1, x_2, \dots, x_n)$, las cuales se multiplican por un vector de pesos $W = (w_1, w_2, \dots, w_n)$. Esto se resume en la siguiente suma $\sum_{i=1}^n x_i w_i$. También se añade valor denominado sesgo, que es un término independiente cuyo fin es otorgar flexibilidad en el aprendizaje de conceptos. Por último a la salida de cada perceptrón se le aplica una transformación no lineal, llamada función de activación $g(z)$. En conclusión, la salida de cada neurona se expresa como 2.1.

$$\hat{y} = g(z) = \sum_{i=1}^n x_i w_i + b \quad (2.1)$$

Para este modelo la función de activación que mejores resultados otorgó es la tangente hiperbólica, definida como $\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}} = \frac{1 - e^{-2x}}{1 + e^{-2x}}$.

En particular en este trabajo se desarrollaron modelos de aprendizaje profundo, que son redes neuronales multicapa [8]. Estas arquitecturas están compuestas por al menos 3 capas. La primera es denominada capa de entrada, que suele tener tantas neuronas como la longitud de los vectores de entrada. A ésta le sigue la capa oculta, y luego sigue una capa de salida, con tantas neuronas como la longitud del vector de salida del modelo.

El aprendizaje en estos modelos se da a partir de una función de entrenamiento cuyo objetivo es minimizar el error en las predicciones. Definida una función de error $L(\hat{y}, y)$, el objetivo es minimizar su valor. En este caso se utilizó el entrenamiento por descenso del gradiente. En este algoritmo el error se reduce de forma iterativa buscando un mínimo en la función a través del gradiente. En cada iteración se calcula el siguiente punto en el espacio como una resta entre el punto actual y el gradiente en ese punto multiplicado por un factor de aprendizaje. Desde el punto de vista geométrico, al restar el gradiente lo que sucede es que se están modificando los pesos hacia la dirección donde crece la función, esto es, hacia algún mínimo, que puede ser local o global. Este proceso se repite hasta alcanzar un número máximo de iteraciones. En términos generales ésto se puede representar con la ecuación $p_{i+1} = p_i - \gamma \nabla L(\hat{y}, y)$. Esto se propaga para modificar los pesos de cada neurona mediante la técnica de *back propagation* [8].

Este comportamiento se describe en la figura 2.2. Se visualiza que para un punto T_i se calcula al punto T_{i+1} en la dirección geométrica del mínimo local.




FIGURA 2.2. Ilustración del algoritmo de descenso del gradiente.

2.3.2. Consideraciones físicas

En principio, existe una temperatura mínima y máxima para el agua que circula en el equipo. El rango válido es entre 5 °C y 40 °C. Sin embargo en la práctica no es normal que el agua circule a temperaturas menores a 15 °C por lo que podemos considerar como primer limitación física que la temperatura del agua esté entre los 15 °C y los 40 °C. Por esto la misma respeta la expresión 2.2.

$$t : t \geq 15 \vee t \leq 40 \quad (2.2)$$

Otra consideración es que se deben evitar en lo posible los cambios bruscos de temperatura. El algoritmo actual intenta generar cambios de 0,1 °C. Si bien esto no es un requerimiento, las buenas prácticas en este tipo de tratamientos indican que la temperatura no cambie de forma brusca. Entonces, la bondad del modelo es inversamente proporcional a la magnitud del cambio de temperatura. Esto queda expresado en 2.3.

$$\text{Bondad} \propto \frac{1}{T_i - T_{i+1}} \quad (2.3)$$

Dado que la respuesta del modelo es una temperatura a la que se debe calentar o enfriar el agua, se tiene en cuenta la energía necesaria para el cambio de temperatura a aplicar. Para esto se plantea en la ecuación 2.4 la energía requerida.

$$E = mc\Delta T \quad (2.4)$$

donde

m = masa del agua

c = capacidad calorífica del agua

T = temperatura

En términos generales, los modelos de inteligencia artificial vistos funcionan como sistemas de caja negra [9], es decir, modelos cuyo funcionamiento resulta muy difícil de explicar. Dadas las condiciones físicas del problema, se prefirió un enfoque de caja gris [10], que busca tener mayor control en su funcionamiento y por esto, una mejor capacidad para entender su comportamiento. Para lograr esto se buscó incorporar las condiciones mencionadas al modelo. Se utilizó el enfoque de redes informadas por física [11]. Este tipo de redes se diseñó como una solución para los modelos de aprendizaje profundo diseñados para resolver problemas gobernados por principios físicos esenciales. En este paradigma se restringen las predicciones a soluciones coherentes con tales principios. Para esto incorporan en su aprendizaje los modelos físicos que gobiernan al problema. Esto proporciona una gran versatilidad ya que se tiene la capacidad de aprender de los datos y la de mantener las ecuaciones físicas que rigen en el problema. Para lograr esto, en este trabajo se definió una función de costo específica. Esta función tiene en consideración las ecuaciones vistas en esta sección y la función de error original, que es la diferencia entre la temperatura generada en el paciente y la objetivo. En el siguiente capítulo se explica como se diseñó esta solución.

En la figura 2.3 se muestra un ejemplo de una función de error. El algoritmo de entrenamiento puede converger en algún mínimo local. Para este ejemplo, el mínimo de la sección mas clara de la gráfica es un mínimo que no cumple con las condiciones físicas. Siguiendo esta función para el entrenamiento, es posible que el modelo converja a la solución que no cumple las propiedades físicas del problema.




FIGURA 2.3. Ejemplo de función de costo.

Mediante redes informadas por física se puede modificar la función de costo, penalizando estas secciones, dejando como mínimos a los que cumplan con las propiedades. En la figura 2.4 se muestra un ejemplo como puede quedar la función de costo luego de incorporar los conceptos físicos.




FIGURA 2.4. Ejemplo de función de costo.

2.4. Herramientas de software

Como lenguaje de programación se utilizó Python [12]. Este es un lenguaje de programación de alto nivel, interpretado, y multiparadigma. Cuenta con numerosas funciones propias del lenguaje que facilitan el desarrollo, y una amplia comunidad de soporte. Además es un lenguaje estándar en soluciones de inteligencia artificial. También se utilizó Jupyter-Notebook [13], que es un proyecto que facilita la programación interactiva. Permite dividir al código en celdas y ejecutar todas las sentencias que estén contenidas en una celda. Para el desarrollo de este trabajo se utilizó Visual Studio como entorno de desarrollo integrado. Este entorno permite desarrollar y ejecutar de forma amigable tanto archivos puros en Python como otros con extensión .ipynb, que son los que siguen el proyecto Jupyter-Notebook y el paradigma de ejecución por celdas. Esto permitió un desarrollo ágil de los modelos y los módulos necesarios.

Este trabajo se basó en herramientas de software útiles y de calidad comprobada en la industria por ser estándares. Para la manipulación de diversos objetos matemáticos se utilizó Numpy [**numpy**], que es una biblioteca potente que ofrece múltiples facilidades para estas prácticas. Mediante Matplotlib [**matplotlib**] se visualizaron gráficos que permiten entender mejor las relaciones entre los datos y las comparaciones realizadas. TensorFlow [**tensorflow**] en general y Keras [**keras**] en particular como frameworks para construir redes neuronales, debido a su potencia y a su flexibilidad para definir una función de costo específica y confiable. Además se utilizó Scikit-Learn [**scikit-learn**] como framework para implementar modelos de inteligencia artificial auxiliares y la realización de pruebas preliminares, como para segmentar datos y calcular meta datos.

En la figura 2.5 se muestra un diagrama que busca explicar las herramientas utilizadas y su relación. En el centro están los frameworks de desarrollo de modelos de inteligencia artificial, que son atravesados por herramientas transversales como Numpy y Matplotlib, y están contenidos en Python que es el lenguaje de programación utilizado.

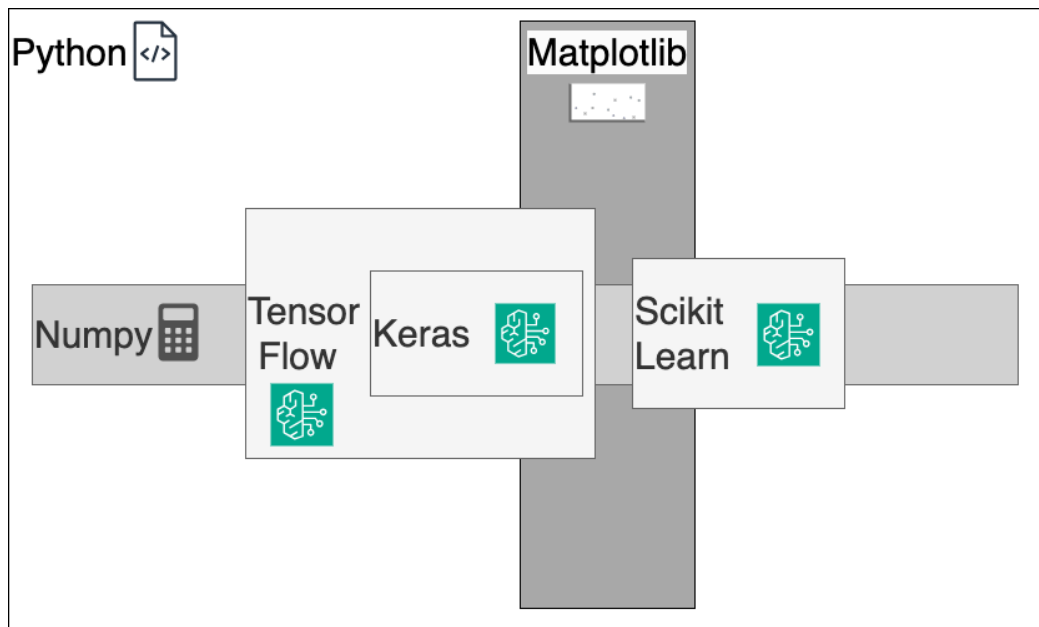


FIGURA 2.5. Diagrama de herramientas de software.

Capítulo 3

Diseño e implementación

A continuación se describirá la solución implementada en el trabajo. Se mostrará la arquitectura utilizada, se comentará como fue el pre procesamiento y análisis de datos. También se analizarán los modelos de inteligencia artificial implementados, su arquitectura y particularidades. Por último se analizará el software integrador implementado.

3.1. Arquitectura general del sistema

Sea x el vector de datos de entrada, el objetivo es consturir un modelo cuya salida y sea la temperatura del agua que debe circular por el equipo para que la temperatura del paciente se aproxime a la objetivo. Se definen tres valores protagonistas. Por un lado, el vector de entrada x , por otro lado la salida del modelo y , y por otro lado la temperatura a la que se lleva al paciente y' si la temperatura del agua en el equipo es y . Se define la función 3.1 como la relación entre x y la temperatura del agua.

$$y = f(x) \quad (3.1)$$

La función 3.2 es la relación entre x' y la temperatura del paciente, siendo x' el vector x incluyendo como temperatura del agua a $y = f(x)$.

$$y' = g(x') \quad (3.2)$$

Se define a la temperatura a la que se lleva al paciente como la composición de las funciones 3.1 y 3.2 en la función 3.3.

$$y' = g(x \circ f(x)) \quad (3.3)$$

A partir de estas funciones se ve que se deben representar dos relaciones. En primer lugar, dado un vector de datos de entrada x , cómo influye en la temperatura que tendrá el paciente en el siguiente periodo de tiempo, y en segundo lugar, dado un vector de datos de entrada x cuál es la temperatura óptima del agua. Las dos relaciones son necesarias para el trabajo y ambas deben ser resueltas a partir de los datos. Para resolver estas relaciones se implementaron dos modelos de inteligencia artificial.

La arquitectura de los modelos implementados para representar estas funciones se muestra en la figura 3.1.




FIGURA 3.1. Arquitectura de modelos del trabajo.

El modelo 1 implementa a la función 3.2. Fue entrenado en primera instancia a partir los datos del conjunto de datos recibido por el cliente. El modelo 2 implementa a la función 3.1. Para entrenar este modelo la función de error no fue estándar. No existe, a priori, un vector y con los valores certeros a los que el modelo 2 debe definir la temperatura del agua. Para entrenar al modelo 2 se debió utilizar al modelo 1, como se muestra en el círculo que representa a la función del error. El error se define como la diferencia entre la temperatura a la que se lleva al paciente con la salida del modelo y la objetivo. Se debe tener en cuenta que para definir a que temperatura se lleva al paciente dado un conjunto de datos se utiliza un modelo, que se entrenó a partir de los datos, y tiene un error en sus predicciones. Para el entrenamiento del modelo 2 no se deben modificar los pesos del modelo 1. Este último ya fue entrenado y debe utilizarse como caja negra. Se puede resolver este problema con un sólo modelo, cuyas últimas capas se entrenen en una etapa y sus primeras etapas, después. Pero este enfoque es mas complejo de implementar y ofrece menor claridad conceptual, por lo que se optó por la solución planteada.

3.2. Análisis de los datos

La empresa envió datos del tratamiento de casi 100 pacientes. Los datos estaban representados en tres formatos diferentes correspondientes a versiones del software del equipo, y en archivos de extensión .txt y .xlsx. El equipo realiza una medición cada 15 minutos. Por esto cada tratamiento esta representado con dos

secciones. La primera con información del paciente. De esta sección se consideraron el peso y la edad, ignorando cualquier dato identificatorio para resguardar la privacidad del paciente. La segunda consta de un conjunto con todas las mediciones realizadas por el equipo cada 15 minutos durante todo el tratamiento.

Los datos considerados son los siguientes:

- EDAD, en días.
- PESO, en gramos.
- FECHA INICIO, inicio del tratamiento.
- REG: Número de Registro.
- T_SP: Temperatura objetivo.
- T_H2O: Temperatura del agua que absorbe el calor del paciente.
- T_PAC: Temperatura del paciente.
- MODO DE USO: Indica el modo de uso configurado.
- RAMPA_HAB: Modo rampa habilitada, esto es influir en la temperatura del paciente para llevarla hacia el objetivo o hacia la normal, o deshabilitada, que consiste en mantener la temperatura estable.
- RAMPA_SET: Indica la tasa de recalentamiento configurada para la función de rampa en $^{\circ}\text{C} / \text{h}$.
- FECHA, de la medición.

La distribución de las temperaturas de los pacientes se muestran en la figura 3.2. La de las objetivo, en la figura 3.3, y la del peso de los pacientes en la imagen 3.4. Se ven algunos valores extremos, como temperaturas de pacientes cercanas a los 0°C . Se verá en la siguiente sección el tratamiento que se da a estas anomalías.




FIGURA 3.2. Distribución de temperaturas de los pacientes.




FIGURA 3.3. Distribución de temperaturas objetivo.

En la figura 3.5 se muestra la correlación entre las variables de los datos recibidos.

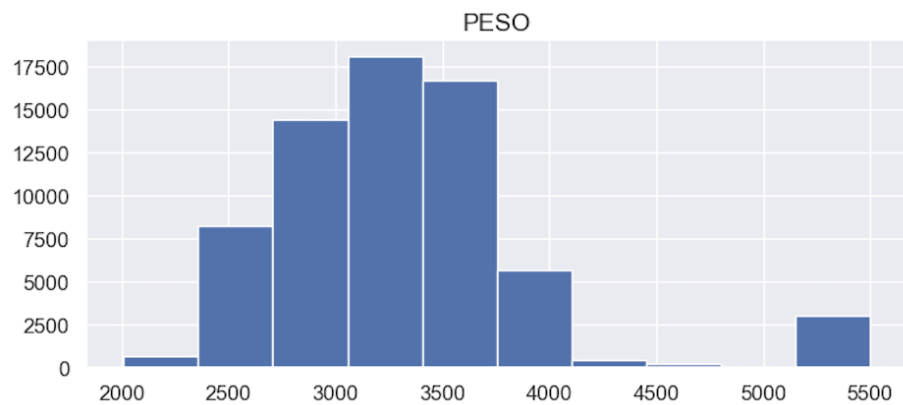


FIGURA 3.5. Correlación entre las variables.

3.3. Preprocesamiento de datos

Capítulo 4

Ensayos y resultados

4.1. Pruebas funcionales del hardware

La idea de esta sección es explicar cómo se hicieron los ensayos, qué resultados se obtuvieron y analizarlos.

Capítulo 5

Conclusiones

5.1. Conclusiones generales

La idea de esta sección es resaltar cuáles son los principales aportes del trabajo realizado y cómo se podría continuar. Debe ser especialmente breve y concisa. Es buena idea usar un listado para enumerar los logros obtenidos.

Algunas preguntas que pueden servir para completar este capítulo:

- ¿Cuál es el grado de cumplimiento de los requerimientos?
- ¿Cuán fielmente se pudo seguir la planificación original (cronograma incluido)?
- ¿Se manifestó algunos de los riesgos identificados en la planificación? ¿Fue efectivo el plan de mitigación? ¿Se debió aplicar alguna otra acción no contemplada previamente?
- Si se debieron hacer modificaciones a lo planificado ¿Cuáles fueron las causas y los efectos?
- ¿Qué técnicas resultaron útiles para el desarrollo del proyecto y cuáles no tanto?

5.2. Próximos pasos

Acá se indica cómo se podría continuar el trabajo más adelante.

Bibliografía

- [1] AAmrra. <https://amrra.com/>. 2024.
- [2] George Imataka et al. «Brain Hypothermia Therapy and Targeted Temperature Management for Acute Encephalopathy in Children: Status and Prospects». En: *Journal of Clinical Medicine* 12.6 (2023). ISSN: 2077-0383. DOI: [10.3390/jcm12062095](https://doi.org/10.3390/jcm12062095). URL: <https://www.mdpi.com/2077-0383/12/6/2095>.
- [3] Christoph Dibiasi et al. «Predicting Intraoperative Hypothermia Burden during Non-Cardiac Surgery: A Retrospective Study Comparing Regression to Six Machine Learning Algorithms». En: *Journal of Clinical Medicine* 12.13 (2023). ISSN: 2077-0383. DOI: [10.3390/jcm12134434](https://doi.org/10.3390/jcm12134434). URL: <https://www.mdpi.com/2077-0383/12/13/4434>.
- [4] Pradeep Singh et al. «Early prediction of hypothermia in pediatric intensive care units using machine learning». En: *Frontiers in Physiology* 13 (2022). ISSN: 1664-042X. DOI: [10.3389/fphys.2022.921884](https://doi.org/10.3389/fphys.2022.921884). URL: <https://www.frontiersin.org/journals/physiology/articles/10.3389/fphys.2022.921884>.
- [5] Micheal Francis Kalyango et al. «Interpretable Machine Learning Regressors for Mild Hypothermia Prediction in General Surgical Operations». En: (2023), págs. 975-982. DOI: [10.1109/ICOEI56765.2023.10125880](https://doi.org/10.1109/ICOEI56765.2023.10125880).
- [6] Egemen Nazife Yazlik y Omer Galip Saracoglu. «A deep learning-based real-time hypothermia and hyperthermia monitoring system with a simple body sensor». En: *Proceedings of the Institution of Mechanical Engineers, Part H: Journal of Engineering in Medicine* 238.7 (2024). PMID: 39104260, págs. 827-836. DOI: [10.1177/09544119241266375](https://doi.org/10.1177/09544119241266375). eprint: <https://doi.org/10.1177/09544119241266375>. URL: <https://doi.org/10.1177/09544119241266375>.
- [7] Sayma Shammi et al. «Machine learning-based detection of freezing events using infrared thermography». En: *Computers and Electronics in Agriculture* 198 (2022), pág. 107013. ISSN: 0168-1699. DOI: <https://doi.org/10.1016/j.compag.2022.107013>. URL: <https://www.sciencedirect.com/science/article/pii/S0168169922003301>.
- [8] Ian Goodfellow, Yoshua Bengio y Aaron Courville. *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press, 2016.
- [9] Timon Rabczuk y Klaus-Jürgen Bathe. «Machine Learning in Modeling and Simulation: Methods and Applications». En: *Computational Methods in Engineering the Sciences* (2023).
- [10] Yimin Yang et al. «Gas turbine engine transient performance and heat transfer effect modelling: A comprehensive review, research challenges, and exploring the future». En: *Applied Thermal Engineering* 236 (2024), pág. 121523. ISSN: 1359-4311. DOI: <https://doi.org/10.1016/j.applthermaleng.2023.121523>. URL: <https://www.sciencedirect.com/science/article/pii/S1359431123015521>.

- [11] Salvatore Cuomo et al. *Scientific Machine Learning through Physics-Informed Neural Networks: Where we are and What's next*. 2022. arXiv: [2201.05624](https://arxiv.org/abs/2201.05624) [cs.LG]. URL: <https://arxiv.org/abs/2201.05624>.
- [12] Guido van Rossum. *Python*. <https://www.python.org/>.
- [13] *Jupyter*. <https://jupyter.org/>.